



Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н. Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н. Э. Баумана)

ФАКУЛЬТЕТ «Информатика и системы управления»

КАФЕДРА «Программное обеспечение ЭВМ и информационные технологии»

РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА

К НАУЧНО-ИССЛЕДОВАТЕЛЬСКОЙ РАБОТЕ

НА ТЕМУ:

«Сравнение алгоритмов поиска объектов на изображениях с использованием различных модификаций сверточных нейронных сетей»

Студент ИУ7-71Б
(Группа)

(Подпись, дата)

Постнов С. А.
(Фамилия И. О.)

Руководитель НИР

(Подпись, дата)

Кузнецова О. В.
(Фамилия И. О.)

2024 г.

РЕФЕРАТ

Расчетно-пояснительная записка 23 с., 9 рис., 1 табл., 12 источн., 1 прил.
CNN, ПОИСК ОБЪЕКТОВ НА ИЗОБРАЖЕНИИ, YOLO, R-CNN, FAST
R-CNN, FASTER R-CNN.

Цель работы — сравнение алгоритмов поиска объектов на изображениях с использованием различных модификаций сверточных нейронных сетей.

В результате работы был проведен анализ предметной области алгоритмов поиска объектов на изображениях, описаны основные подходы к решению задачи распознавания объектов на изображениях. Сформулированы критерии сравнения применяемых методов и выполнено их сравнение.

СОДЕРЖАНИЕ

ОПРЕДЕЛЕНИЯ	5
ОБОЗНАЧЕНИЯ И СОКРАЩЕНИЯ	6
ВВЕДЕНИЕ	7
1 Описание предметной области	8
1.1 Задача поиска объекта на изображении	8
1.2 Сверточные нейронные сети для поиска объектов на изображениях	8
1.2.1 YOLO	10
1.2.2 R-CNN	12
1.2.3 Fast R-CNN	14
1.2.4 Faster R-CNN	16
2 Сравнение модификаций CNN при решении задач поиска объектов на изображении	18
2.1 Критерии сравнения модификаций CNN	18
2.2 Результаты сравнения	18
2.3 Вывод	19
ЗАКЛЮЧЕНИЕ	20
ПРИЛОЖЕНИЕ А	21
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	23

ОПРЕДЕЛЕНИЯ

В настоящей расчетно-пояснительной записке применяют следующие термины с соответствующими определениями.

Нейронная сеть — математическая модель, а также её программное или аппаратное воплощение, построенная по принципу организации биологических нейронных сетей.

ОБОЗНАЧЕНИЯ И СОКРАЩЕНИЯ

В настоящей расчетно-пояснительной записке применяют следующие сокращения и обозначения.

МИ — Медицинские изображения

CNN — Convolutional neural network

RPN — Region Proposal Network

YOLO — You Only Look Once

IOU — Intersection Over Union

FPS — Frames Per Second

R-CNN — Regional Convolutional Neural Networks

SVM — Support Vector Machine

mAP — Mean Average Precision

ВВЕДЕНИЕ

Технологии компьютерного зрения и искусственного интеллекта находят применение в разных сферах человеческой деятельности. Важным и интересным направлением, где возможно применение данных технологий, является анализ объектов на медицинских изображениях. На сегодняшний день анализ МИ и поиск объектов на них широко применяется в медицинской диагностике – от анализа крови до магниторезонансной томографии. До недавнего времени задачи анализа МИ решались с использованием различных алгоритмов, основанных на использовании гистограмм градиентов, алгоритмов каскадных классификаторов на основе метода Виолы – Джонса, алгоритмов, основанных на методах контурного анализа и др. Традиционные методы анализа МИ и поиска на них объектов достигли своего предела производительности. Аналогично медицинской сфере, подход распознавания объектов с использованием нейронных сетей нашел свое применение и в задачах мониторинга морского дна [1; 2].

Для решения задачи распознавания объектов зачастую выбирают сверточные нейронные сети из-за простоты реализации, минимальных системных требований и хорошего процента распознавания объектов. Сверточная нейронная сеть (CNN) – частный случай искусственных нейронных сетей глубокого обучения. Архитектура сверточных сетей была предложена Яном Лекуном в 1988 году с целью повышения эффективности распознавания образов [3; 4].

Целью работы является сравнение алгоритмов поиска объектов на изображениях с использованием различных модификаций сверточных нейронных сетей. Для достижения поставленной цели необходимо решить следующие задачи:

- 1) провести анализ предметной области алгоритмов поиска объектов на изображениях;
- 2) описать основные подходы к решению задачи распознавания объектов на изображениях;
- 3) сформулировать критерии сравнения применяемых методов и выполнить их сравнение.

1 Описание предметной области

1.1 Задача поиска объекта на изображении

Задача поиска объекта на изображении сводится к решению следующих подзадач [5]:

- 1) сегментация — выделение участков изображения, которые относятся к разным объектам;
- 2) классификация — определение типа объекта, для каждого выделенного сегмента отдельно.

Таким образом, обнаружение объектов — это процесс сегментации и классификации объектов в изображении.

1.2 Сверточные нейронные сети для поиска объектов на изображениях

Сверточные нейронные сети являются наиболее распространенным алгоритмом глубокого обучения, применяющим несколько сверточных слоев и вычислений. Они предоставляют эффективные способы извлечения признаков, а также являются лучшим выбором для решения проблем обнаружения объектов. Текущие подходы с использованием методов глубокого обучения для задач классификации и регрессии объектов можно разделить на две категории [6]:

- 1) двухэтапные методы, которые представлены такими архитектурами, как R-CNN, Fast R-CNN и Faster R-CNN;
- 2) одноэтапные методы, представленные различными версиями YOLO и др.

Описанные методы представлены на рисунке 1.1.

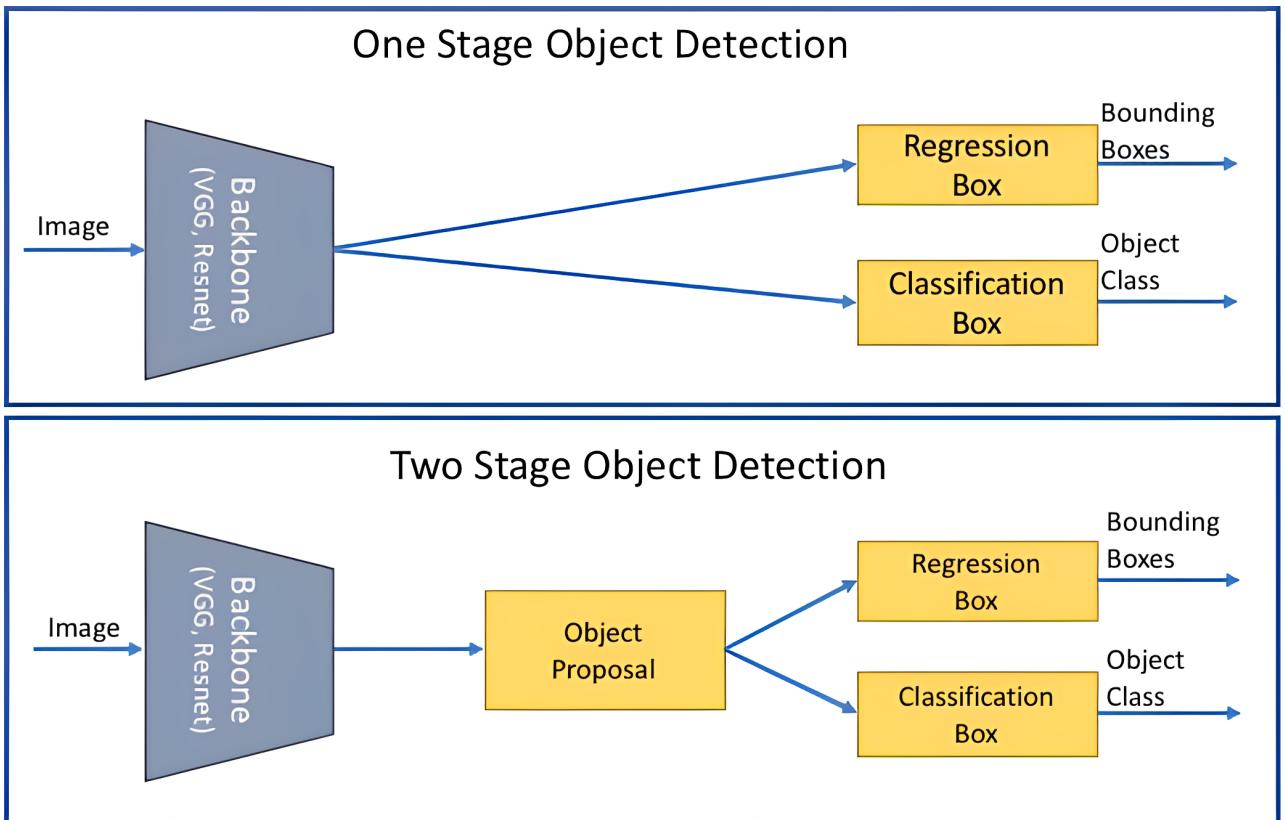


Рисунок 1.1 – Двухэтапный и одноэтапный методы

В двухэтапных методах используется селективный поиск или сеть региональных предположений (англ. RPN) для выделения областей, с высокой вероятностью содержащих внутри себя объекты. Затем, при помощи классификатора, определяется класс объекта, а при помощи регрессора определяются ограничивающие рамки. Данный метод обладает высокой точностью, но при этом ограничен в скорости обнаружения.

Одноэтапные методы не используют отдельную сеть для генерации регионов и основываются на методах регрессии, просматривая изображения целиком. Так как данные алгоритмы не используют RPN, скорость обнаружения выше, но точность выделения, в особенности малых объектов, не такая высокая, как у двухэтапных методов [6].

1.2.1 YOLO

YOLO — сеть, предназначенная для идентификации и распознавания объектов на изображениях в реальном времени. Такой подход к обнаружению объектов называется «Вы смотрите только один раз» (YOLO), что означает распознавание объектов сразу после первого прохода по изображению. Метод YOLO рассматривает обнаружение объектов как задачу регрессии с пространственно разделенными ограничивающими рамками и соответствующими вероятностями классов, которые прогнозируются с помощью одной нейронной сети на основе полных изображений в ходе одной оценки. YOLO быстра по своей конструкции и действительно работает в режиме реального времени, сохраняя большую точность [6; 7].

Базовая модель YOLO также называется YOLO версии 1 (YOLOv1). Она решает задачу обнаружения объектов на изображении как задачу регрессии. Одна сверточная сеть одновременно предсказывает множество ограничивающих рамок и вероятности классов для этих рамок. YOLOv1 разбивает входное изображение на сетку $S \times S$. Если центр объекта попадает в ячейку сетки, эта ячейка отвечает за обнаружение этого объекта. Каждая ячейка сетки предсказывает B ограничивающих рамок, показатели достоверности для этих рамок и вероятности класса C для сетки. Эти прогнозы закодированы в виде тензора $S \times S \times (B \times 5 + C)$. В процессе тестирования YOLOv1 умножает условные вероятности классов и прогнозы достоверности отдельных блоков, которые дают оценки для каждого блока, относящиеся к конкретному классу по формуле 1.1 [7].

$$Pr(Class_i|Object) \times Pr(Object) \times IOU_{pred}^{truth} = Pr(Class_i) \times IOU_{pred}^{truth} \quad (1.1)$$

Оценки отражают вероятность появления этого класса в поле и схожесть поля с объектом. Каждое ограничивающее поле состоит из 5 прогнозов: x , y , w , h и достоверности. Координаты (x, y) представляют центр прямоугольника относительно границ ячейки сетки. Ширина w и высота h рассчитываются относительно всего изображения. Именно поэтому YOLOv1 использует выражение $B \times 5$ для вычисления тензора. Сеть YOLOv1 состоит из 24 сверточных слоев, за которыми следуют 2 полностью соединенных слоя. Вместо начальных модулей, используемых в GoogLeNet, YOLOv1 использует

слой сокращения 1×1 , за которым следуют сверточные слои 3×3 . В Pascal VOC2007 YOLOv1 обрабатывает изображения со скоростью 45 кадров в секунду (FPS), что в 2 – 9 раз быстрее, чем у Faster R-CNN. В частности, Fast YOLO, быстрая версия YOLO, разработанная для расширения возможностей быстрого обнаружения объектов, достигает 155 кадров в секунду (FPS) [6; 7].

Архитектура YOLOv1 CNN представлена на рисунке 1.2.

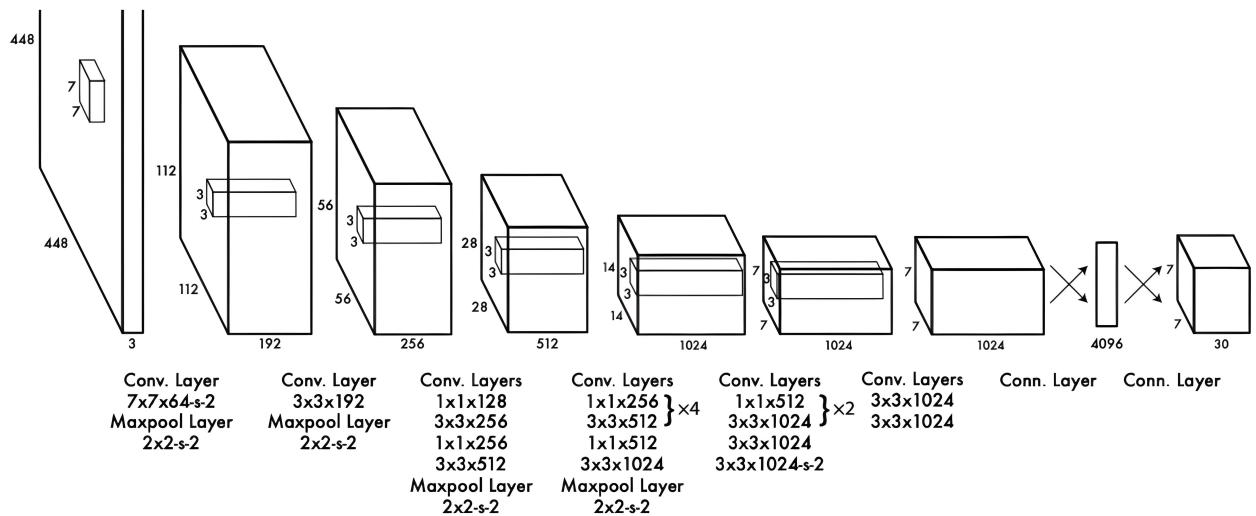


Рисунок 1.2 – Архитектура YOLOv1 CNN

YOLO версии 2 (YOLOv2) — значительно улучшенная модель YOLO, которая сохраняет преимущество в скорости и пытается повысить качество распознавания по сравнению с YOLOv1. Используя новый многомасштабный метод обучения, одна и та же модель YOLOv2 может работать в разных размерностях, предлагая простой компромисс между скоростью и качеством. Алгоритм лучше справляется с небольшими объектами и реагирует быстрее, чем ранее доступные версии. Одноступенчатая архитектура предполагает наличие только одной нейронной сети для прогнозирования ограничивающей рамки и вероятности категории. YOLOv2 имеет множество улучшений по сравнению со своими предшественниками и другими алгоритмами. В первую очередь, YOLOv2 использует Darknet-19 с 19 сверточными слоями и 5 слоями Max-Pooling и вводит якорные рамки (anchor boxes), что позволяет лучше адаптироваться к объектам разных размеров. Вместо абсолютных значений координаты предсказываются как смещения относительно якорных рамок, для каждой из которых модель предсказывает параметры координат, уверенность и вероятности классов [8; 9].

Архитектура YOLOv2 CNN представлена на рисунке 1.3.

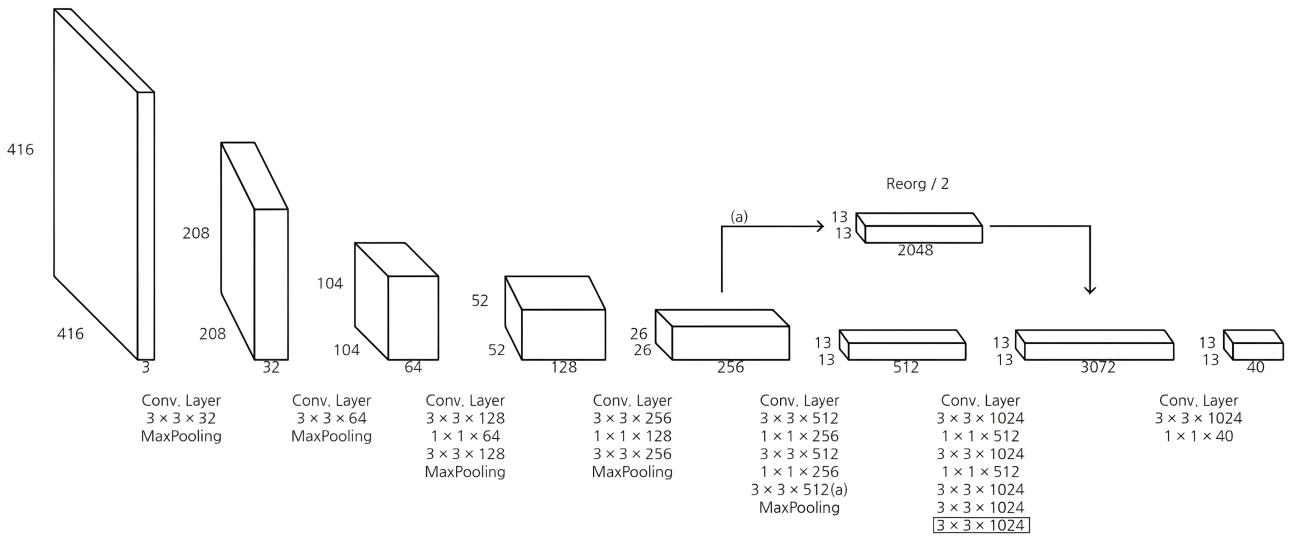


Рисунок 1.3 – Архитектура YOLOv2 CNN

1.2.2 R-CNN

В последнее время для решения задачи поиска объектов на изображении широкое распространение получили алгоритмы, основанные на применении региональных глубоких сверточных нейронных сетей или Regional Convolutional Neural Networks (R-CNN), которые принципиально ориентированы на решение задачи поиска объектов с одновременной их классификацией. Исходная реализация таких моделей базируются на использовании специальных алгоритмов предобработки — алгоритмов region-proposal-function, обеспечивающих предложение так называемых областей внимания, в которых потенциально могут находиться интересующие объекты. Описанный подход предлагает сократить вычислительные затраты, а также позволяют добиться минимального времени определения местоположения объекта и высокой точности его классификации. К настоящему моменту имеется большое количество вариантов реализации подобных алгоритмов, которые достигли хороших показателей по данным критериям [10].

Алгоритм работы R-CNN состоит из следующих основных шагов:

- 1) выполняется генерация областей интереса (region proposals), предположительно содержащих в себе искомые объекты (обычно до 2000 возможных областей) с использованием различных алгоритмов, предназначенных для снижения вычислительной сложности

обнаружения объектов на изображении (например, алгоритмы Edge Boxes, Selective search);

- 2) выполняется формирование карты признаков для исходного изображения путем аффинных преобразований, и каждая область интереса преобразуется в квадрат 227×227 , так как используемая архитектура CNN требует входы фиксированного размера 227×227 пикселей;
- 3) выполняется классификация объектов для каждой области интереса с использованием сформированного вектора признаков на основе метода опорных векторов (SVM).

Для оценки качества классификации, аналогично модели YOLO, используется показатель *IOU*. Считается, что объект обнаружен правильно, если данный показатель превышает некоторый порог, в противном случае считается, что объект не обнаружен [8; 10].

Схема алгоритма работы R-CNN представлена на рисунке 1.4.



Рисунок 1.4 – Схема алгоритма работы R-CNN

Пример распознавания с использованием R-CNN представлен на рисунке 1.5.

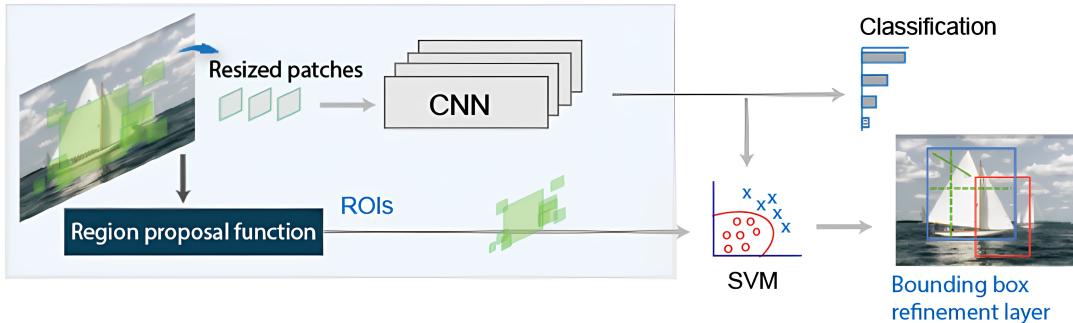


Рисунок 1.5 – Пример распознавания с использованием R-CNN

1.2.3 Fast R-CNN

Модель Fast R-CNN является улучшением классической модели R-CNN, которая известна своей низкой производительностью, особенно при взаимодействии с более глубокими сетями. Также, при использовании R-CNN затрачивается большой объем памяти для хранения данных.

Алгоритм работы Fast R-CNN состоит из следующих основных шагов [8; 10]:

- 1) аналогично R-CNN выполняется генерация областей интереса (region proposals);
- 2) выполняется формирование карты признаков для исходного изображения, но, в отличие от R-CNN, на вход нейронной сети CNN подается полное исходное изображение с последним слоем ROI pooling вместо Max pooling;
- 3) выполняется уточнение границ области интереса при помощи регрессионной модели (Bounding Box Regression);
- 4) выполняется классификация объектов, содержащихся в предполагаемых областях интереса с использованием слоя softmax с $K + 1$ выходами.

Схема алгоритма работы Fast R-CNN представлена на рисунке 1.6.



Рисунок 1.6 – Схема алгоритма работы Fast R-CNN

Пример распознавания с использованием Fast R-CNN представлен на рисунке 1.7.

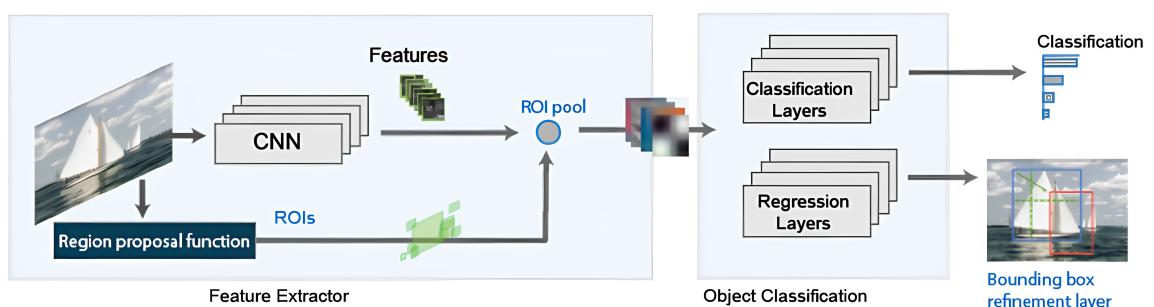


Рисунок 1.7 – Пример распознавания с использованием Fast R-CNN

1.2.4 Faster R-CNN

Faster R-CNN представила сеть региональных предложений (RPN), основанную на Fast R-CNN, которая заменяет внешний алгоритм для генерации областей интереса, предположительно содержащих объект. Области интереса (region proposals) используют такую информацию, как текстура, границы и цвет изображения, чтобы заранее определить положение, в котором может появиться искомый объект, что может гарантировать более высокую скорость отклика при меньшем количестве выбранных окон (несколько сотен или даже несколько тысяч). Такой подход значительно сокращает временные затраты на последующие операции и позволяет получить искомое окно, а не скользящее более высокого качества. В некотором смысле, Faster R-CNN можно представить в виде объединения RPN и Fast R-CNN. Эта модификация R-CNN уже предоставила результат с эталонной точностью распознавания, поэтому единственным улучшением будет являться скорость работы, что является основной причиной появления более поздних алгоритмов [11].

Алгоритм работы Faster R-CNN состоит из следующих основных шагов [8; 10; 11]:

- 1) выполняется формирование карты признаков на основе исходного изображения при помощи CNN;
- 2) выполняется генерация областей интереса, возможно содержащих объект, за счет обработки скользящим окном размера 3×3 сформированной карты признаков с использованием RPN;
- 3) выполняется преобразование вектора признаков области интереса из исходного изображения в вектор признаков фиксированной размерности с помощью слоя RoI pooling;
- 4) аналогично шагу 3 алгоритма работы Fast R-CNN выполняется уточнение границ области интереса;
- 5) аналогично шагу 4 алгоритма работы Fast R-CNN выполняется классификация объектов, содержащихся в предполагаемых областях интереса.

Схема алгоритма работы Faster R-CNN представлена на рисунке 1.8.



Рисунок 1.8 – Схема алгоритма работы Faster R-CNN

Пример распознавания с использованием Faster R-CNN представлен на рисунке 1.9.

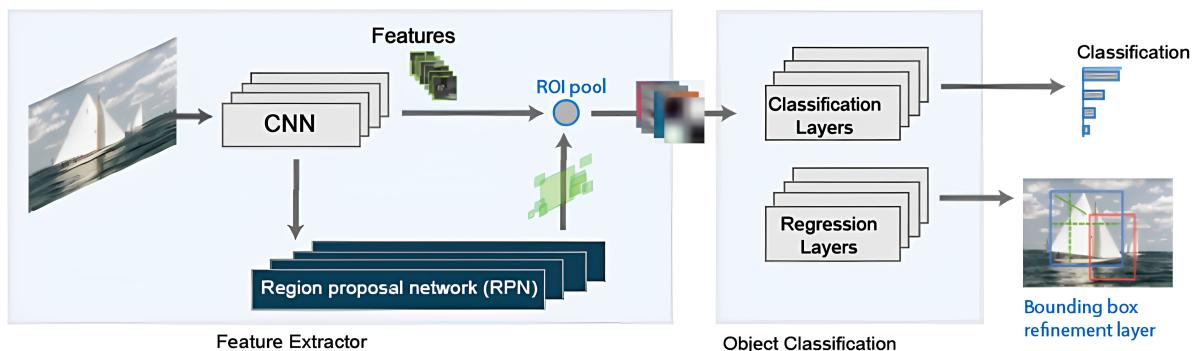


Рисунок 1.9 – Пример распознавания с использованием Faster R-CNN

2 Сравнение модификаций CNN при решении задач поиска объектов на изображении

2.1 Критерии сравнения модификаций CNN

Для сравнения модификаций сверточных нейронных сетей будут использоваться следующие основные критерии [6; 7; 9; 12]:

- 1) mAP;
- 2) FPS;
- 3) PS.

Критерий mAP показывает точность модели и вычисляется по формуле 2.1.

$$mAP = 1/N \sum_{i=1}^N AP_i \quad (2.1)$$

, где N — количество классов, AP (average precision) — популярная метрика для измерения точности детекторов объектов.

Критерий FPS показывает, сколько кадров в секунду может обрабатывать нейронная сеть.

Критерий PS показывает общую оценку каждой системы распознавания, основываясь на том, что точность и скорость имеют одинаковый вес и вычисляется по формуле 2.2.

$$PS = mAP \times FPS \quad (2.2)$$

2.2 Результаты сравнения

В таблице 2.1 представлены количественные результаты сравнения различных модификаций сверточных нейронных сетей на основе сформированных критериев [7; 9].

Таблица 2.1 – Количественные результаты сравнения различных модификаций CNN на основе сформированных критериев

Модификация CNN	mAP	FPS	PS
R-CNN Minus R	53.5	6	321.0
Fast R-CNN	70.0	0.5	35.0
Faster R-CNN VGG-16	73.2	7	512.4
Faster R-CNN ResNet	76.4	5	382.0
YOLOv1	63.4	45	2853.0
YOLOv2 288×288	69.0	91	6279.0
YOLOv2 352×352	73.7	81	5970.0
YOLOv2 416×416	76.8	67	5146.0
YOLOv2 480×480	77.8	59	4590.2
YOLOv2 544×544	78.6	40	3144.0

2.3 Вывод

Исходя из полученной сравнительной таблицы 2.1, можно выделить следующие пункты:

- 1) по двум из трех сформированных критериев лидирует модель YOLOv2 288×288 , обладающая наибольшим значением FPS и PS;
- 2) наибольшей точностью обладает модель YOLOv2 544×544 (по критерию mAP);

Таким образом, можно сделать вывод, что использование класса моделей YOLO может применяться в задачах поиска изображений в реальном времени, так как именно эти модификации CNN обладают наибольшим значением FPS (от 40 до 91). Модели класса Faster R-CNN имеют аналогичные значения mAP в сравнении с моделями YOLO, однако скорость обработки изображений меньше \sim в 7 – 9 раз относительно модели YOLOv2 544×544 , и в \sim в 13 – 18 раз относительно модели YOLOv2 288×288 . Сеть Fast R-CNN обладает наименьшей скоростью поиска объектов (FPS) среди всех представленных модификаций CNN, а самая базовая модель R-CNN Minus R имеет наименьший показатель точности (mAP).

ЗАКЛЮЧЕНИЕ

Цель работы, заключавшаяся в сравнении алгоритмов поиска объектов на изображениях с использованием различных модификаций сверточных нейронных сетей, была достигнута.

Были решены следующие задачи:

- 1) проведен анализ предметной области алгоритмов поиска объектов на изображениях;
- 2) описаны основные подходы к решению задачи распознавания объектов на изображениях;
- 3) сформулированы критерии сравнения применяемых методов и выполнено сравнение.

ПРИЛОЖЕНИЕ А

Презентация к научно-исследовательской работе состоит из 4 слайдов

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. *A. B. Руденко, M. A. Руденко, И. Л. Каширина.* Применение искусственных нейронных сетей для поиска объектов на медицинских изображениях // Моделирование, оптимизация и информационные технологии. — 2024. — С. 480.
2. *B. С. Быкова, A. И. Машошин, A. С. Смирнов.* Способ распознавания назначенного донного объектах. — 2024.
3. *Д. А. Дасаева, В. В. Мокшин.* ПРИМЕНЕНИЕ СВЕРТОЧНЫХ НЕЙРОННЫХ СЕТЕЙ ДЛЯ ПОИСКА ОБЪЕКТОВ НА ИЗОБРАЖЕНИЯХ // ИНФОРМАЦИОННЫЕ СИСТЕМЫ И ТЕХНОЛОГИИ. — 2021.
4. *И. И. Багаев.* АНАЛИЗ ПОНЯТИЙ НЕЙРОННАЯ СЕТЬ И СВЕРТОЧНАЯ НЕЙРОННАЯ СЕТЬ, ОБУЧЕНИЕ СВЕРТОЧНОЙ НЕЙРОСЕТИ ПРИ ПОМОЩИ МОДУЛЯ TENSORFLOW // Математическое и программное обеспечение в промышленной и социальной сферах. — 2020.
5. *E. Ю. Митрофанова.* Поиск объектов на изображениях с использованием TensorFlow Object Detection. — 2022.
6. *M. C. Тимошкин, A. H. Миронов, A. С. Леонтьев.* СРАВНЕНИЕ YOLOV5 И FASTERR-CNN ДЛЯ ОБНАРУЖЕНИЯ ЛЮДЕЙ НА ИЗОБРАЖЕНИИ В ПОТОКОВОМ РЕЖИМЕ // Международный научно-исследовательский журнал. — 2022.
7. *Juan Du.* Understanding of Object Detection Based on CNN Family and YOLO // Journal of Physics: Conference Series. — 2018.
8. Research on Image Recognition of Tuberculosis Lesions by Minimally Invasive Surgical Robot Based on YOLOv2 / Guo Yu [и др.] // ARTIFICIAL INTELLIGENCE AND ROBOTICS RESEARCH. — 2024.
9. *Joseph Redmon, Ali Farhadi.* YOLO9000: Better, Faster, Stronger. — 2017.
10. *A. A. Сирота, E. Ю. Митрофанова, A. И. Милованова.* АНАЛИЗ АЛГОРИТМОВ ПОИСКА ОБЪЕКТОВ НА ИЗОБРАЖЕНИЯХ С ИСПОЛЬЗОВАНИЕМ РАЗЛИЧНЫХ МОДИФИКАЦИЙ

СВЕРТОЧНЫХ НЕЙРОННЫХ СЕТЕЙ // ВЕСТНИК ВГУ, СЕРИЯ: СИСТЕМНЫЙ АНАЛИЗ И ИНФОРМАЦИОННЫЕ ТЕХНОЛОГИИ. — 2019.

11. A Fusion Steganographic Algorithm Based on Faster R-CNN / Ruohan Meng [и др.] // Tech Science Press. — 2018.
12. С. Ю. Колбасов, Ю. К. Орлов. СРАВНЕНИЕ ЭФФЕКТИВНОСТИ ОБНАРУЖЕНИЯ ОБЪЕКТОВ СОВРЕМЕННЫХ СВЕРТОЧНЫХ НЕЙРОННЫХ СЕТЕЙ // ИНФОРМАТИКА, УПРАВЛЯЮЩИЕ СИСТЕМЫ, МАТЕМАТИЧЕСКОЕ И КОМПЬЮТЕРНОЕ МОДЕЛИРОВАНИЕ (ИУСМКМ-2020). — 2020.